

Análisis de los perfiles físicos de los deportistas que participan en el NFL Combine.



[SantiagoLazos/NFL-Combine-: Proyecto de Ciencia de Datos en el cual se realiza un análisis sobre las marcas y características de los jugadores prospectos a participar en la NFL.](#)

Santiago Adrian Lazos Ovalle
Benemérita Universidad Autónoma de Puebla

Introducción

El NFL Combine es uno de los eventos más importantes en el proceso de reclutamiento de la National Football League (NFL). Cada año, cientos de jugadores universitarios realizan una serie de pruebas físicas y atléticas diseñadas para evaluar su velocidad, fuerza, explosividad y agilidad. Estas métricas permiten a entrenadores, scouts y analistas comparar el rendimiento físico de los prospectos y proyectar su potencial en el nivel profesional.

En este proyecto se aplican herramientas de Ciencia de Datos para analizar más de diez años de información histórica del Combine y descubrir patrones ocultos dentro del rendimiento físico de los atletas. A diferencia de un análisis tradicional basado únicamente en estadísticas descriptivas, aquí se emplea Machine Learning no supervisado, específicamente el algoritmo K-Means, con el objetivo de identificar agrupamientos naturales de jugadores según sus atributos físicos. Este enfoque permite comprender cómo se diferencian los atletas entre sí sin necesidad de usar su posición o una etiqueta predefinida.

Para lograrlo, se realizó un proceso completo que incluye:

- Limpieza y depuración del dataset,
- Análisis Exploratorio de Datos (EDA),
- Identificación de outliers mediante el método del Rango Intercuartílico (IQR),
- Estandarización de variables físicas,
- Aplicación del método del codo para determinar la cantidad óptima de clusters,

Y finalmente, una interpretación detallada de los perfiles atléticos resultantes.

El objetivo final de este proyecto es producir una caracterización clara de los diferentes tipos de atletas que participan en el Combine, entender qué posiciones se concentran en cada grupo, y generar visualizaciones que faciliten la interpretación de estos hallazgos. Además, este análisis demuestra cómo la Ciencia de Datos puede utilizarse en contextos reales del deporte para apoyar la toma de decisiones, la detección de talento y la evaluación objetiva de jugadores.

Este documento presenta paso a paso la metodología utilizada, los resultados obtenidos y las conclusiones derivadas del análisis, mostrando el valor que las técnicas de análisis de datos aportan al entendimiento del rendimiento atlético en el fútbol americano profesional.

Para este proyecto trabajé con un conjunto de datos histórico del NFL Combine, que abarca información desde el año 1987 hasta 2017. Este dataset reúne miles de registros de jugadores universitarios que participaron en diferentes pruebas físicas, permitiendo analizar cómo ha cambiado el rendimiento atlético a través de los años y qué perfiles destacan en cada una de las posiciones del fútbol americano profesional.

El dataset original tenía más de diez mil registros, pero después del proceso de limpieza, depuración y eliminación de valores inválidos, terminé trabajando con un dataset final de 8,781 jugadores y un total de 16 variables completamente válidas. Estas variables se pueden dividir en tres grupos principales:

Datos Antropométricos

Estos atributos son esenciales para entender el tipo de físico que tiene cada jugador y qué roles puede desempeñar dentro del campo. Incluyen:

- Height (in): Altura del jugador en pulgadas.
- Weight (lbs): Peso corporal en libras.
- Arm Length (in): Longitud del brazo, clave para linieros y alas defensivas.
- Hand Size (in): Tamaño de la mano, importante en posiciones donde el manejo del balón es crítico.

Pruebas Físicas

Estas pruebas son las más conocidas del Combine y evalúan distintos aspectos del rendimiento atlético:

- 40 Yard Dash: Tiempo en segundos para recorrer 40 yardas. Es la métrica más famosa y mide velocidad pura.
- Bench Press: Número de repeticiones con 225 libras; mide fuerza del tren superior.
- Vertical Jump (in): Altura del salto vertical, indicador de explosividad.
- Broad Jump (in): Distancia del salto horizontal, también relacionado con potencia de piernas.
- Shuttle: Prueba de agilidad 5–10–5, que evalúa reacción y cambio de dirección.
- 3 Cone Drill: Mide agilidad general y capacidad para cambiar de dirección a ritmo rápido.
- 60Yd Shuttle: Versión extendida del shuttle, evaluando agilidad y resistencia.

Además de los valores numéricos, el dataset también tiene columnas que identifican a cada jugador. En esta parte se encuentran:

- POS (Posición del jugador): Aquí se incluyen todas las posiciones del fútbol americano. En el dataset aparecen las siguientes: (Ofensa, Defensa, Equipos Especiales)

QB: Quarterback, RB: Running Back, FB: Fullback, WR: Wide Receiver, TE: Tight End, C: Center, G / OG: Guard / Offensive Guard y OT / OL: Offensive Tackle / Offensive Line.

DT: Defensive Tackle, DE: Defensive End, DL: Defensive Lineman, LB / ILB / OLB: Linebacker (interno / externo), CB: Cornerback, DB: Defensive Back, FS: Free Safety y SS: Strong Safety

K: Kicker y P: Punter

Estas posiciones representan todos los roles principales dentro del campo, y son clave para interpretar los perfiles físicos que encontré con clustering.

El hecho de tener métricas homogéneas y comparables entre jugadores facilita la aplicación de modelos de clustering, lo que me permitió encontrar perfiles atléticos naturales sin tener que usar la posición como etiqueta.

En pocas palabras, este dataset me dio la oportunidad de analizar profundamente cómo se comportan los atletas del NFL Combine y de descubrir patrones que serían difíciles de notar a simple vista.

Limpieza de la Base de Datos

Para poder analizar correctamente el dataset del NFL Combine, primero fue necesario realizar un proceso de limpieza completo. El dataset original tenía registros de más de 30 años (1987–2017), pero contenía valores faltantes, datos imposibles y errores comunes en este tipo de recopilaciones históricas. Antes de aplicar cualquier técnica de análisis, me aseguré de dejar la base totalmente limpia, coherente y lista para trabajar.

Antes de entrar al análisis profundo, revisé cada columna para identificar valores que no aportaban nada o estaban totalmente vacíos. En mi caso, la mayoría de las columnas sí contenían información útil, así que el enfoque principal fue limpiar valores incorrectos más que eliminar columnas completas.

Uno de los problemas más comunes en el Combine son los valores que representan “falta de registro” pero aparecen como si fueran datos reales. Algunos ejemplos que encontré:

- Shuttle y 3 Cone tenían un montón de valores exactamente en 10.0 segundos, lo cual es imposible en la vida real.
- La prueba 60 Yd Shuttle tenía valores repetidos en 11.65, que también se usan como marcadores de “dato faltante”.

Esos tiempos no existen en atletas profesionales, así que los removí para evitar que contaminaran el análisis.

Después de eliminar los valores imposibles, revisé cuántos datos faltantes había en el dataset. La mayoría de las métricas importantes quedaron sin valores vacíos, y cualquier registro que no cumplía con las pruebas clave o tenía datos incompletos fue filtrado.

Esto dejó el dataset más consistente y sin huecos que pudieran afectar.

Al analizar las distribuciones, encontré que algunas métricas tenían valores fuera de lo normal, como jugadores con tiempos exageradamente altos en pruebas de velocidad. Para manejar esto, usé el método del IQR, que ayuda a identificar valores que están demasiado lejos del comportamiento normal de los datos.

Primero calculé:

- Q1: Percentil 25
- Q3: Percentil 75
- $IQR = Q3 - Q1$

El criterio tradicional usa $1.5 * IQR$, pero en mi caso ese valor estaba eliminando demasiados datos válidos, así que ajusté el rango a $2 * IQR$, lo cual me permitió:

- Mantener un dataset más grande (más de 8,600 jugadores).
- Eliminar únicamente outliers verdaderamente extremos.
- Conservar valores reales sin perder precisión en el análisis.

Esto garantizó que eliminara solo valores físicos imposibles sin afectar la integridad del dataset.

Después de corregir valores erróneos, eliminar outliers y depurar datos faltantes, revisé nuevamente todo el dataset. El resultado final quedó así:

- 8,781 registros
- 0 valores nulos
- Todas las métricas dentro de rangos reales
- Distribuciones normales y coherentes
- Datos listos para el EDA y el modelo K-Means

En otras palabras, la base quedó totalmente limpia y lista para análisis serio.

Después de todo el proceso, obtuve un dataset consistente, confiable y representativo del desempeño real de los jugadores del NFL Combine. Gracias a esta limpieza previa, las etapas siguientes como el EDA, la visualización y el clustering dieron resultados claros, coherentes y con sentido físico y deportivo.

Análisis Exploratorio de Datos

El Análisis Exploratorio de Datos (EDA) es una de las partes más importantes del proyecto, ya que permite entender el comportamiento de las variables del Combine antes de aplicar cualquier modelo de Machine Learning. En esta sección analicé la distribución de las métricas físicas, detecté patrones, relaciones, valores extremos y características importantes según posición.

El dataset final contiene 8,781 jugadores y 16 columnas, correspondientes a características físicas (altura, peso, medidas corporales), rendimiento en pruebas del Combine (40 Yard, Bench Press, Vertical, Broad Jump, Shuttle, 3 Cone, 60 Yd Shuttle) y variables categóricas como la posición del jugador, la universidad y el año.

```
8 df.shape
✓ 0.0s
(10432, 16)
```


En la imagen de la izquierda es la base de datos original, la del lado derecho es la que use.

```
5 df.shape
✓ 0.0s
(8781, 16)
```

Para analizar el comportamiento interno de cada prueba, generé histogramas y boxplots de las métricas numéricas. Estas visualizaciones permiten identificar valores típicos, amplitud de rangos y posibles valores anómalos.


Algunas observaciones clave:

- 40 Yard Dash: La mayoría de los jugadores se concentra entre 4.3 y 5.1 segundos, con una pequeña cola hacia tiempos mayores.
- Bench Press: Distribución centrada entre 15 y 25 repeticiones, con jugadores de líneas siendo quienes más repeticiones alcanzan.
- Vertical y Broad Jump: Se observan distribuciones simétricas, propias de pruebas de explosividad.
- Weight: Los pesos varían según posición, pero la distribución general muestra que la mayoría de atletas pesa entre 190 y 260 libras.



A través de un mapa de calor (heatmap), analicé la correlación entre las métricas físicas. Este análisis reveló varios patrones interesantes:


- Existe una correlación negativa fuerte entre el peso y la velocidad: jugadores más pesados suelen tener tiempos más altos en la prueba de 40 yardas.
- Las pruebas de salto vertical y broad jump tienen correlación positiva, algo esperado ya que ambas miden explosividad.
- Las pruebas de agilidad (Shuttle y 3 Cone) presentan correlación moderada entre sí, indicando que tienen componentes comunes pero no idénticos.



Este punto está totalmente conectado con la limpieza previa, pero también es parte del EDA.


Algunos tiempos imposibles y valores repetidos fueron removidos previamente.

El análisis visual confirmó que, después del ajuste del IQR, las distribuciones quedaron limpias, sin puntos irregulares ni valores fuera del rango humano.



Esta es una comparativa de Fuerza vs Velocidad, antes de Realizar el IQR

Esta es la misma comparativa entre Fuerza vs Velocidad, después de Realizar el IQR



Después de toda la depuración, el dataset final quedó con 0 valores nulos, esto facilita enormemente el análisis, ya que evita eliminar registros adicionales.

Year	0	40 Yard	0
Name	0	Bench Press	0
College	0	Vert Leap (in)	0
POS	0	Broad Jump (in)	0
Height (in)	0	Shuttle	0
Weight (lbs)	0	3Cone	0
Hand Size (in)	0	60Yd Shuttle	0
Arm Length (in)	0	dtype: int64	
Wonderlic	0		

Para esta parte analicé cómo se comportan las métricas físicas según la posición del jugador (POS). Generé boxplots de 40 Y por posición, así como comparaciones de peso y fuerza según las posiciones principales.

Hallazgos importantes:

- WR y CB presentan los mejores tiempos en velocidad y agilidad.
- DT, OL y DL muestran los pesos más altos y las menores velocidades.
- RB y LB ocupan rangos intermedios, lo que corresponde a su rol híbrido entre fuerza y movilidad.
- Los QB tienen un perfil más variado, ya que su posición no depende completamente de su físico.

De todo el EDA podemos destacar varias conclusiones clave:

- Los atletas del Combine se agrupan naturalmente en perfiles físicos según su posición, incluso antes de aplicar Machine Learning.
- Las pruebas físicas tienen relaciones lógicas entre sí: velocidad vs peso, explosividad vertical vs horizontal, agilidad en shuttle vs 3 cone.

- Los linieros presentan consistentemente métricas de fuerza y tamaño por encima del promedio, mientras que receptores y esquineros dominan en velocidad y explosividad.
- Las métricas del Combine están bien estandarizadas, lo que convierte este dataset en un excelente candidato para clustering.

Este EDA permitió entender el comportamiento de los atletas y fundamentó las decisiones sobre cómo preparar los datos para el modelo K-Means.

K-Means

Después de limpiar el dataset y entender el comportamiento general de las variables con el EDA, el siguiente paso fue aplicar un modelo de Machine Learning no supervisado para encontrar grupos naturales de jugadores según su rendimiento físico.

En este caso utilicé K-Means, un algoritmo de clustering que agrupa observaciones similares sin necesitar una etiqueta previa (como “bueno” o “malo”). Esto encaja perfectamente con la idea del proyecto: dejar que los datos del Combine formen sus propios perfiles de jugadores.

Planteamiento del problema

Mi objetivo con el modelo no era predecir una variable específica, sino descubrir qué tipos de atletas existen dentro del Combine en términos de velocidad, fuerza, explosividad y tamaño.

En lugar de decirle al modelo “este es receptor, este es liniero, este es corredor”, preferí usar únicamente las métricas físicas y ver qué grupos se formaban de manera natural. Después, comparé esos grupos con las posiciones reales para interpretar los resultados.

Justificación del uso de K-Means

Elegí K-Means por varias razones:


- Es un modelo no supervisado, ideal cuando no hay una etiqueta objetivo clara.
- Funciona muy bien cuando se trabaja con variables numéricas, como tiempos, pesos y alturas.
- Es relativamente sencillo de implementar y de interpretar, algo importante en un proyecto académico donde no solo importa el resultado, sino entender el proceso.
- Permite asignar cada jugador a un cluster y después analizar esos grupos con gráficas, tablas y descripciones.

En pocas palabras, K-Means me permite pasar de una tabla grande de números a perfiles de jugadores bien definidos.

Una decisión importante en K-Means es elegir cuántos clusters (k) se van a formar. Para eso utilicé el método del codo (Elbow Method).



La idea fue entrenar el modelo varias veces, probando distintos valores de k (por ejemplo, de 1 a 10), y para cada uno calcular la inercia, que mide qué tan compactos están los clusters. Luego, se grafica el número de clusters contra la inercia.


En la gráfica se observa un descenso fuerte de la inercia entre $k = 1$ y $k = 4$, y a partir de ahí la mejora es cada vez menor. El “codo” de la curva aparece claramente en $k = 4$, por lo que elegí: tener 4 clusters.



El modelo asignó a cada jugador un número de cluster (0, 1, 2 o 3). Esta nueva columna de cluster se añadió al dataframe, lo que permitió:

- Visualizar los grupos en diferentes gráficas de dispersión.
- Cruzar los clusters con las posiciones reales de los jugadores.
- Analizar qué tipo de atleta domina en cada grupo.







Una vez entrenado el modelo, analicé qué características tenía cada cluster combinando:

- Las métricas físicas promedio de cada grupo.
- Las distribuciones en las gráficas.
- La proporción de posiciones en cada cluster (usando tablas y gráficas de pastel).

De forma general, los clusters se pueden describir así:

- Cluster 0:
Jugadores más pesados y fuertes, con tiempos más altos en velocidad.
Aquí se concentran principalmente linieros ofensivos y defensivos (OL, OT, OG, C, DT, DL).
Son los típicos jugadores de trinchera.

- Cluster 1:
Atletas con balance entre fuerza y velocidad.
Incluye muchos running backs, wide receivers y algunos linebackers, con buen rendimiento en varias pruebas físicas.
- Cluster 2:
Jugadores de tamaño intermedio y roles mixtos.
Aquí aparecen quarterbacks, alas cerradas y defensive ends, que combinan cierta fuerza, altura y movilidad, pero no siempre son los más rápidos del campo.
- Cluster 3:
Este es el cluster de velocidad y agilidad pura.
Domina en él un alto porcentaje de wide receivers y cornerbacks, con los mejores tiempos en 40 yardas y excelentes resultados en pruebas de agilidad como Shuttle y 3 Cone.



El uso de K-Means permitió pasar de una tabla con miles de filas y muchas columnas a cuatro perfiles atléticos bien definidos.

Más allá de lo académico, este tipo de análisis podría servir para:

- Identificar qué tipo de atleta es más común en cada posición.
- Detectar jugadores que físicamente se parecen a cierto perfil exitoso.
- Explorar si hay jugadores “atípicos” dentro de su propia posición, pero que encajan físicamente con otro rol.

En resumen, el modelo de clustering funciona como una herramienta para entender mejor el Combine desde la perspectiva de la Ciencia de Datos y abre la puerta a aplicaciones más avanzadas en scouting y análisis deportivo.

Desarrollo de Cada Cluster

Cluster 0


Este cluster agrupa principalmente a jugadores con:

- Peso significativamente mayor al promedio.
- Mayor fuerza en Bench Press.
- Velocidad más baja en la prueba de 40 Yardas.
- Menor explosividad en vertical y broad jump.

Los atletas de este cluster presentan cuerpos grandes, mucha fuerza en el tren superior y menor movilidad, algo totalmente lógico para su rol.

Posiciones que dominan este cluster:

- OL (Offensive Linemen: OT, OG, C)
- DL (Defensive Linemen: DT, DE)



Interpretación:

Este grupo representa a los jugadores de trinchera, cuya función principal es proteger, bloquear y detener la carrera. Sus pruebas del Combine reflejan desempeño en fuerza, tamaño y potencia, más que velocidad pura. Las características físicas encajan perfectamente con posiciones que requieren imponerse en la línea de golpeo.


Cluster 1

En este cluster se encuentran jugadores con un buen equilibrio entre:

- Velocidad decente en 40Y.
- Fuerza media en Bench Press.
- Medidas corporales intermedias.
- Buen desempeño en pruebas de salto y agilidad.

Posiciones que dominan este cluster:

- RB
- WR
- LB (especialmente OLB)
- DB (especialmente SS / FS)



Interpretación:

Este grupo representa jugadores versátiles que combinan velocidad, potencia y agilidad. Son atletas que pueden cumplir múltiples roles dentro del campo. Este cluster es el más equilibrado en términos físicos y muestra la típica constitución de jugadores que requieren adaptarse a situaciones ofensivas y defensivas.


Cluster 2

Este cluster es muy interesante porque captura atletas:

- De estatura y peso medianos.
- Con fuerza moderada.
- No tan rápidos como los WR/CB, pero tampoco tan grandes como OL/DL.
- Rendimiento mixto en agilidad y explosividad.

Posiciones que dominan este cluster:

- QB
- TE
- DE (ligeros)
- Algunos RB grandes o WR altos



Interpretación:

Este grupo representa atletas híbridos, que no destacan en una sola métrica, sino que combinan varias características de manera uniforme. Estas posiciones requieren inteligencia, tamaño razonable y habilidades mixtas, que coinciden con los atributos promedio observados en este cluster.


Cluster 3

Este es el cluster más fácil de identificar porque presenta a los jugadores con:

- Mejores tiempos en 40 Yardas.
- Mayor explosividad en vertical y broad jump.
- Excelente desempeño en Shuttle y 3 Cone.
- Peso y altura por debajo del promedio.

Posiciones que dominan este cluster:

- WR
- CB
- FS/SS veloces
- RB



Interpretación:

Este cluster representa a los velocistas puros del Combine. Son jugadores explosivos, ágiles y con tiempos sobresalientes en pruebas de cambio de dirección. Su físico y rendimiento coinciden con roles donde la velocidad es el componente más importante, como cubrir rutas, generar separación o reaccionar al receptor.

Conclusión

El análisis del NFL Combine utilizando técnicas de Ciencia de Datos permitió identificar patrones físicos claros y consistentes entre los atletas que participaron entre 1987 y 2017. A través de un proceso completo que incluyó limpieza del dataset, análisis exploratorio, estandarización de variables y un modelo de clustering no supervisado, fue posible agrupar a los jugadores en cuatro perfiles atléticos bien definidos.

El EDA reveló relaciones lógicas entre las pruebas del Combine, como la correlación negativa entre peso y velocidad, y la correlación positiva entre las pruebas de salto. Además, los comportamientos observados en cada posición coincidieron con las características físicas que se esperan en el campo de juego: linieros con mayor fuerza y tamaño, receptores y esquineros con la mejor velocidad, y atletas híbridos con rendimiento intermedio.

El modelo K-Means, con $k = 4$, permitió identificar grupos naturales sin necesidad de utilizar las posiciones como etiqueta. Los clusters formados demostraron que los datos sí tienen estructura interna y que las métricas físicas del Combine son capaces de diferenciar perfiles de jugadores. Esto validó el uso de Machine Learning en contextos deportivos donde el talento y el rendimiento físico pueden analizarse objetivamente.

En general, el proyecto demostró que la Ciencia de Datos puede aportar herramientas valiosas para el análisis del rendimiento atlético, permitiendo obtener una visión más profunda y estructurada del NFL Combine. Esta metodología podría ser utilizada por equipos, scouts y analistas para identificar talento, comparar prospectos o reconocer perfiles físicos específicos dentro de una clase de jugadores.